

PERAWATAN PREDIKTIF UNTUK SISTEM PRODUKSI DENGAN PENDEKATAN ANALISIS BIG DATA DAN KECERDASAN BUATAN MENGUNAKAN DATA KONDISI MESIN DAN INFORMASI KUALITAS YANG REAL TIME

Outline Disertasi Doktorat — ITB, 2025 | Toto Suharto

LOGIKA STRUKTUR DISERTASI

Bab III berisi metodologi bersama (shared) yang berlaku untuk keseluruhan disertasi: kerangka konseptual, dataset, dan infrastruktur evaluasi. Bab IV dan V masing-masing membuka dengan sub-bab metodologi spesifiknya sendiri sebelum masuk ke hasil — sehingga pembaca melihat dengan jelas perbedaan metode antara studi diagnostik (WDCNN + SHAP + FSM) dan studi prognostik (Backbone RUL + Top-k SAE).

Alur: Bab I (konteks) → Bab II (teori) → Bab III (fondasi bersama) → Bab IV (metode + hasil: Diagnostik) → Bab V (metode + hasil: Prognostik) → Bab VI (sintesis + kesimpulan)

BAB I — PENDAHULUAN

I.1 Latar Belakang

→ Bearing = 40–50% kegagalan rotating machinery. Gap: akurasi AI tinggi tapi kepercayaan industrial rendah karena tidak ada bukti fisika.

→ Dua gap yang belum terisi: (1) XAI diagnostik belum ada di level sinyal mentah; (2) model RUL belum terbukti menginternalisasi fisika degradasi (BPFx) dalam ruang latennya.

I.2 Rumusan Masalah

→ RQ1: Pola atribusi SHAP pada sinyal mentah 2.048 titik — berkorelasi dengan morfologi impuls atau periodisitas BPFx?

→ RQ2: Dapatkah Top-k SAE mengekstrak fitur laten model RUL yang berkorespondensi dengan BPFx secara statistik signifikan?

→ RQ3: Bagaimana kedua kerangka membentuk sistem PdM yang interpretable dan dapat diaudit?

I.3 Tujuan dan Novelti

- N1: *FSM — XAI level sinyal pertama untuk WDCNN (resolusi 2.048 titik, 3 varian, 3 metrik validasi).*
- N2: *Trade-off BatchNorm — temuan pertama BatchNorm menekan discriminability FSM; panduan desain arsitektur.*
- N3: *SAE→Bearing — adaptasi pertama mechanistic interpretability (LLM) ke domain bearing prognostics.*
- N4: *Universalitas — 3 arsitektur × 4 dataset, statistical rigor (bootstrap CI + permutation test + negative controls).*
- N5: *Integrasi — kerangka diagnostik–prognostik terpadu, dua lapis interpretabilitas, PdM multi-tier.*

I.4 Batasan Masalah

- *Diagnostik: CWRU, Load 0–3, 48 kHz, 10 kelas, segmen 2.048 titik.*
- *Prognostik: PHM2012, XJTU-SY, IMS. Arsitektur: WDCNN (diagnostik); Mamba-xLSTM / N-BEATS-xLSTM / SparseGate-TCN (prognostik).*

I.5 Sistematika Penulisan

- *Enam bab: Bab III = fondasi bersama; Bab IV = metode+hasil diagnostik; Bab V = metode+hasil prognostik; Bab VI = sintesis.*

BAB II — TINJAUAN PUSTAKA

II.1 Perawatan Prediktif dan Industri 4.0

- *Evolusi CBM (ISO 13374/13381). Ekosistem sensor dan IoT industri.*

II.2 Diagnostik Bearing Berbasis Deep Learning

II.2.1 Evolusi Arsitektur

- *SVM+statistik → CNN 1D → WDCNN (Zhang 2017) → hybrid CNN-LSTM → Transformer.*

II.2.2 Dataset CWRU

- *Protokol, jenis kesalahan (EDM-seeded), isu temporal leakage pada random split.*

II.3 Explainable AI: Input Attribution

II.3.1 Taxonomy Metode XAI

- *Gradient-based, propagation (LRP), perturbation (SHAP). Hampir semua beroperasi di level fitur — gap yang dijawab Paper 1.*

II.3.2 SHAP DeepExplainer

- *Shapley values, rescale rule DeepLIFT. Kelebihan dan keterbatasan.*

II.4 Prognostik Bearing: Estimasi RUL

II.4.1 Fisika vs. Data-Driven

→ *Model Paris/Archard vs. LSTM→Transformer→Mamba/xLSTM. Tren: akurasi saturasi → trustworthiness.*

II.4.2 Benchmark Dataset RUL

→ *PHM2012, XJTU-SY, IMS. Metrik: RMSE, skor PHM (penalti asimetris terlambat > lebih awal).*

II.5 Mechanistic Interpretability dan Sparse Autoencoders

II.5.1 Superposition dan Top-k SAE

→ *Elhage 2022 (superposition), Bricken/Cunningham 2023 (Top-k SAE). Monosemantisitas sebagai tujuan.*

II.5.2 Gap: Belum Ada SAE untuk Bearing

→ *Bearing = test case lebih bersih dari bahasa; BPFx = set konsep fisika terdefinisi yang harus ada di latent space model terlatih.*

II.6 Fisika Getaran Bearing

→ *Formula BPFO, BPFI, BSF, FTF. Envelope analysis (Hilbert transform) sebagai referensi validasi kuantitatif.*

II.7 Peta Gap Literatur

→ *Matriks: level interpretabilitas × dataset × validasi statistik × integrasi diagnostik–prognostik. Posisi Paper 1 dan Paper 2.*

BAB III — METODOLOGI UMUM

Bab ini memuat fondasi bersama: kerangka konseptual yang menghubungkan kedua studi, spesifikasi seluruh dataset, dan infrastruktur evaluasi yang digunakan oleh Bab IV maupun Bab V. Metodologi spesifik masing-masing studi dijelaskan di awal Bab IV dan Bab V.

III.1 Kerangka Konseptual Terintegrasi

→ *Dua jalur paralel yang konvergen: (A) CWRU→WDCNN→SHAP→FSM [Bab IV]; (B) PHM/XJTU/IMS→Backbone RUL→SAE→BPFx [Bab V].*

→ *Konvergensi di Bab VI: kerangka PdM multi-tier yang menggabungkan input-attribution (FSM) dan latent-concept interpretability (SAE).*

III.2 Dataset

III.2.1 CWRU — digunakan di Bab IV

→ *10 kelas, Drive-End 48 kHz, Load 0–3. Segmen 2.048 titik, temporal split 54/13/33% → 1.240/310/750 sampel. Z-score normalisasi.*

III.2.2 PHM2012 — digunakan di Bab V

→ 17 bearing FEMTO-PRONOSTIA, 3 kondisi beban. EOL: $RMS > 20g$. Split bearing-wise. Label RUL linier $1 \rightarrow 0$.

III.2.3 XJTU-SY — digunakan di Bab V

→ 10 bearing LDK UER204, outer-race spalling dominan. Split bearing-wise.

III.2.4 IMS — digunakan di Bab V

→ 4 bearing Rexnord, 2.000 rpm, akuisisi tiap 10 menit. Bearing 3: outer-race; bearing 4: rolling-element fatigue.

III.3 Metrik Evaluasi Bersama

→ Diagnostik (Bab IV): akurasi, macro-F1, confusion matrix.

→ Prognostik (Bab V): RMSE ↓, MAE ↓, skor PHM (penalti asimetris).

→ Interpretabilitas (Bab IV): discriminability, severity monotonicity, split-half stability.

→ Interpretabilitas (Bab V): hit-rate H_{ω} , bootstrap 95% CI, permutation p-value.

BAB IV — BEARING FAULT DETECTION: METODOLOGI DAN HASIL

Backbone: Paper 1 (FSM Paper) — WDCNN + SHAP DeepExplainer + Fault Signature Maps pada dataset CWRU.

[METODOLOGI STUDI DIAGNOSTIK]

IV.1 Arsitektur WDCNN

→ Kernel pertama: lebar 64, stride 16. Blok konvolusi 2–5: kernel 3. Dua lapisan FC(100), dropout 0.5, softmax 10 kelas. ~60.710 parameter.

→ Tiga varian ablasi yang diuji: (A) baseline, (B) kernel sempit $k=3$, (C) tanpa BatchNorm.

→ Pelatihan: Adam $lr=0.001$, StepLR, CrossEntropyLoss, early stopping patience=15.

IV.2 SHAP DeepExplainer pada Sinyal Mentah

→ Background: 300 sampel terstratifikasi (30/kelas). Target eksplanasi: 500 sampel uji (50/kelas).

→ Output: 10 array atribusi (500×2.048) = 10,24 juta nilai SHAP per model.

→ Operasi pada sinyal mentah 2.048 titik — berbeda dari semua studi sebelumnya yang beroperasi di level fitur.

IV.3 Formalisasi Fault Signature Maps (FSM)

→ Signed FSM: rata-rata atribusi dengan tanda. Absolute FSM: rata-rata nilai absolut (dipakai sebagai sidik jari utama). Variance FSM: variansi antar sampel.

→ Tiga metrik validasi: (i) discriminability index, (ii) severity monotonicity fraction, (iii) split-half stability coefficient.

[HASIL DAN ANALISIS]

IV.4 Kinerja Klasifikasi WDCNN

→ Akurasi 99,87% (749/750). Macro $F1 = 0,997$. Early stopping epoch ke-54. Satu misklasifikasi: Ball_014 → IR_014.

→ vs. SVM-RBF 96,4%: reduksi error pengujian 91%.

IV.5 Pola Atribusi SHAP

→ Tiga karakteristik global: suppression tepi (0–100, 1.900–2.048), modulasi ~16 sampel (artefak stride), distribusi merata $|\phi| \approx 0,015$ –0,025.

→ Profil per kelas: Normal (rendah) → Ball (difus) → IR (datar) → OR (terlokalisasi); OR_021 puncak $|\phi| \approx 0,08$ di posisi 600–700.

IV.6 Validasi FSM

→ Split-half stability = 0,940. Discriminability index = 0,216. Severity monotonicity: Ball 17,6% > IR 13,8% > OR 8,6%.

IV.7 Interpretasi Fisika: Morfologi vs. Periodisitas

→ Puncak FSM TIDAK selaras dengan periode BPFx teoritis.

→ Temuan kritis: WDCNN mengklasifikasikan via morfologi transien impuls (42,67 ms), bukan via periodisitas BPFx. Implikasi: model tidak butuh geometri bearing atau kecepatan poros → lebih transferable.

IV.8 Studi Ablasi: Trade-off BatchNorm

→ Varian A (baseline): akurasi 99,73%, discriminability 0,216.

→ Varian B (kernel sempit $k=3$): akurasi ↓ 0,80pp; parameter ↑ 7,3×; discriminability ↑ 17%.

→ Varian C (tanpa BatchNorm): akurasi ↓ 3,60pp; discriminability ↑ 133% (→ 0,735). Temuan pertama dalam literatur.

→ Panduan desain: Varian A untuk akurasi kritis; Varian C untuk interpretabilitas maksimum.

BAB V — REMAINING USEFUL LIFE: METODOLOGI DAN HASIL

Backbone: Paper 2 (SAE Paper) — Backbone RUL + Top-k Sparse Autoencoders + BPFx Mapping pada PHM2012, XJTU-SY, IMS, CWRU.

[METODOLOGI STUDI PROGNOSTIK]

V.1 Arsitektur Backbone RUL

→ Mamba-xLSTM-Net: selective state-space + matrix-memory xLSTM. Konteks panjang + presisi rekuren.

→ N-BEATS-xLSTM-RUL: basis-block (trend/wear/shock) + xLSTM residual. Prior struktural kurva degradasi.

→ *SparseGate-TCN-RUL*: dilated causal convolution + sparse gating. Latensi rendah, baseline ringan.

→ *Protokol*: 75 epoch, bf16, batch $512 \times \text{window-32}$, 3 seed (42/43/44). Checkpoint loss validasi terbaik.

V.2 Top-k Sparse Autoencoder

→ *Arsitektur*: encoder $W_{enc} \in \mathbb{R}^{(d_{lat} \times d)}$, decoder W_{dec} , bpre bias. $d_{lat} = 8d = 1.024$. $k = 51$ (~5% aktif).

→ *Pelatihan*: pool $N = 20.000$ hidden states (frozen backbone), AdamW $lr=1e-3$, 50 epoch, loss MSE rekonstruksi.

→ *Prinsip*: mendorong monosemantisitas — setiap fitur SAE mengkodekan satu konsep fisika, bukan campuran polysemantic.

V.3 Prosedur Mapping SAE → BPFx

→ *Hilbert envelope spectrum*: band-pass di resonansi dominan (spectral kurtosis), envelope $A_r(t)$, $A_r(\omega) = \int_{-\infty}^{\infty} \{\omega \pm 2\} A_r(f) df$.

→ *Korelasi Pearson* $r_{i,\omega}$ antara profil aktivasi fitur SAE $\bar{z}_{r,i}$ dan amplitudo BPFx $A_r(\omega)$ lintas semua recording.

→ *Hit-rate*: $H_\omega = |\{i: |r_{i,\omega}| \geq 0.30\}| / d_{lat}$. Threshold 0.30 = korelasi moderat secara praktis.

V.4 Inferensi Statistik dan Negative Controls

→ *Bootstrap* $B=1.000$ resample recording → 95% CI untuk H_ω . Permutation test $B=1.000$ shuffle → p -value two-sided.

→ *Control 1* (model belum terlatih, Xavier init): apakah korespondensi artefak arsitektur?

→ *Control 2* (Gaussian noise hidden states): apakah korespondensi artefak prosedur SAE itu sendiri?

→ *Sparsity sweep*: $k \in \{10, 51, 102, 205\}$ untuk uji robustness.

[HASIL DAN ANALISIS]

V.5 Kinerja Backbone RUL

→ *PHM2012*: *SparseGate-TCN* terbaik (RMSE $0,226 \pm 0,030$). *XJTU-SY*: *N-BEATS-xLSTM* terbaik ($0,259 \pm 0,003$). *IMS*: *Mamba-xLSTM* terbaik ($0,407 \pm 0,040$).

→ Semua backbone viable → justified untuk memeriksa makna fisik representasi latennya.

V.6 Hit-Rate BPFx: Hasil Utama

→ *PHM2012*: BPFi 2,3% + BPFO 2,0% ($p < 0,001$); BSF & FTF = 0. ✓ Konsisten: mixed inner+outer-race spalling.

→ *XJTU-SY*: BPFO 2,2% dominan + BSF 0,3% ($p < 0,001$); BPFi & FTF = 0. ✓ Konsisten: outer-race spalling LDK UER204.

→ *IMS*: BPFi 1,76% + BSF 0,49% ($p = 0,001$). ✓ Konsisten: cage & rolling-element fatigue.

→ *CWRU*: BPFi 5,08% dominan ($p > 0,05$, underpowered — $n=10$ recording).

V.7 Negative Controls: Eliminasi Artefak

→ *Control 1 + Control 2: hit-rate turun drastis pada model belum terlatih dan noise → korespondensi adalah emergent property representasi terlatih, bukan artefak arsitektur atau prosedur SAE.*

V.8 Perbandingan Lintas Arsitektur

→ *PHM2012: Mamba-xLSTM memimpin BPFI → model lebih kuat secara temporal → alignment fisika lebih kaya.*

→ *XJTU-SY: Mamba-xLSTM BPFO-dominant (4,69%); arsitektur lain menyebar → bias induktif state-space amplifikasi outer-race.*

→ *CWRU: ketiga arsitektur konvergensi ke BPFI-dominant (4,69–5,08%) → distribusi data mendominasi, bukan bias arsitektur.*

V.9 Sparsity Sweep

→ *$k = 51$ optimal. $k < 10$: beberapa BPFx kehilangan signifikansi. $k > 102$: noise BPFx sekunder meningkat.*

BAB VI — KESIMPULAN DAN REKOMENDASI

VI.1 Pembahasan Terintegrasi

→ *FSM (Bab IV) = input attribution, level sinyal. SAE (Bab V) = latent concept, level hidden state. Dua lapisan berbeda, saling melengkapi.*

→ *Paradoks yang tampak: FSM tidak sejajar BPFx, SAE berkorelasi dengan BPFx. Bukan kontradiksi — mencerminkan perbedaan cakrawala waktu (42,67 ms vs. ratusan akuisisi degradasi).*

→ *Rantai konsistensi: kurtosis/crest factor (fitur) → impuls terlokalisasi (FSM/sinyal) → BPFx di latent space (SAE). Semua lapisan mengeksplorasi tanda fisik underlying yang sama.*

VI.2 Kerangka PdM Multi-Tier

→ *Tier 1 — Edge IoT: SVM/LR + SHAP fitur, triage anomali.*

→ *Tier 2 — Edge Server: WDCNN + FSM, konfirmasi jenis dan keparahan, akurasi 99,87%.*

→ *Tier 3 — Cloud/GPU: Backbone RUL + SAE, estimasi RUL + audit latent-physics via hit-rate BPFx.*

VI.3 Kesimpulan

→ *Lima novelti (N1–N5) terjawab secara kuantitatif. Kontribusi inti: jembatan pertama data-driven AI ↔ classical vibration theory yang dapat diverifikasi statistik.*

VI.4 Keterbatasan

→ *Single operating condition per dataset. CWRU = seeded faults. SAE post-hoc, belum dalam loop pelatihan. CWRU underpowered untuk SAE ($n=10$).*

VI.5 Rekomendasi Penelitian Lanjutan

→ *Validasi Paderborn / MFPT. SAE dalam loop pelatihan. Normalizer-Free Networks. SHAP pada STFT/CWT. Implementasi edge real-time (< 100 ms). Integrasi ERP/CMMS.*

— *Akhir Outline* —