

**PERAWATAN PREDIKTIF UNTUK SISTEM PRODUKSI
DENGAN PENDEKATAN ANALISIS BIG DATA DAN
KECERDASAN BUATAN MENGGUNAKAN DATA KONDISI
MESIN DAN INFORMASI KUALITAS YANG REAL TIME**

DISERTASI

**Karya tulis sebagai salah satu syarat
untuk memperoleh gelar Doktor dari
Institut Teknologi Bandung**

**Oleh
TOTO SUHARTO
NIM: 33420002
(Program Studi Doktor Teknik Dan Manajemen Industri)**



**INSTITUT TEKNOLOGI BANDUNG
Agustus 2025**

ABSTRAK

PERAWATAN PREDIKTIF UNTUK SISTEM PRODUKSI DENGAN PENDEKATAN ANALISIS BIG DATA DAN KECERDASAN BUATAN MENGGUNAKAN DATA KONDISI MESIN DAN INFORMASI KUALITAS YANG REAL TIME

Oleh

TOTO SUHARTO

NIM: 33420002

(Program Studi Doktor Teknik Dan Manajemen Industri)

Pemerintah Indonesia telah berkomitmen untuk membangun industri manufaktur yang kokoh dengan diluncurkannya *Making Indonesia 4.0* pada bulan April 2018 untuk meningkatkan produktivitas di industri manufaktur sehingga meningkatkan daya saing Indonesia secara global dan juga mengangkat pangsa pasar ekspor global. Kelima sektor industri yang menjadi prioritas yaitu industri makanan dan minuman, tekstil, kimia, otomotif dan elektronika, diharapkan menjadi ujung tombak dalam penerapan teknologi industri 4.0, seperti *Internet of Things* (IoT), *3D printing*, robotika maju, analisis *big data* dan kecerdasan buatan.

Saat ini implementasi industri 4.0 di negara-negara Eropa sudah sangat maju, sementara industri manufaktur di Indonesia masih harus mengejar ketinggalan. Salah satu implementasi industri 4.0 adalah perawatan cerdas atau *smart maintenance*. Terdapat dua jenis perawatan yang umum dilakukan pada industri manufaktur saat ini, yaitu perawatan korektif dan perawatan preventif. Kedua jenis perawatan tersebut memiliki kelemahan seperti terjadinya kerusakan mesin yang tidak terduga dan mengakibatkan produksi berhenti atau melakukan pergantian mesin terlalu cepat. Oleh karena itu, diperlukan penerapan perawatan prediktif dengan menggunakan data-data sensor yang dianalisis menggunakan kecerdasan buatan sebagai bentuk penerapan implementasi industri 4.0 yaitu perawatan cerdas.

Penelitian ini bertujuan untuk mengembangkan model perawatan prediktif berbasis integrasi data sensor heterogen, yang mencakup data sensor kondisi mesin serta informasi kualitas produk (misalnya *vibration checking* dan *radial clearance checking*) secara waktu nyata. Pengembangan dilakukan melalui pendekatan gabungan *machine learning* (ML) dan *deep learning* (DL), yang memadukan metode statistik, model ML konvensional, dan arsitektur DL untuk meningkatkan kemampuan deteksi anomali dan prediksi *Remaining Useful Life* (RUL) dengan tetap mempertahankan *Overall Equipment Effectiveness* (OEE) dan kualitas produk sesuai spesifikasi manufaktur.

Selain itu, penelitian ini mengimplementasikan metode *Explainable Artificial Intelligence* (XAI), khususnya SHAP (*SHapley Additive exPlanations*), untuk mengidentifikasi kepentingan fitur dari variabel sensor yang berpengaruh pada

performa mesin dan kualitas produk. Pendekatan ini memberikan transparansi dan interpretabilitas model, sehingga hasil prediksi dapat dipahami dan dipercaya oleh *engineer* serta lebih mudah diadopsi dalam lingkungan industri manufaktur.

Penelitian dimulai dengan melakukan studi literatur mengenai perawatan prediktif secara komprehensif sehingga peta penelitian mutakhir (*state of the art*) dapat digambarkan serta celah teori dengan penelitian sebelumnya didapatkan untuk membuat perumusan masalah dan tujuan penelitian. Selanjutnya akan dilakukan pengujian ulang praktik terbaik mengenai perawatan prediktif pada objek penelitian. Pengembangan model akan dimulai dengan melakukan deteksi anomali pada proses produksi *ball bearing* dengan menerapkan *machine learning* dan *deep learning* pada objek penelitian. Model yang dikembangkan kemudian akan disimplifikasi sesuai dengan kebutuhan objek penelitian.

Secara ilmiah, penelitian ini berkontribusi pada pengembangan perawatan prediktif waktu nyata dengan integrasi data heterogen yang selama ini masih jarang dilakukan, serta menghadirkan model yang tidak hanya akurat tetapi juga dapat dijelaskan. Secara praktis, implementasi model diharapkan mampu mengurangi waktu henti yang tidak terencana, meningkatkan efisiensi operasional dan OEE, menjaga kualitas *ball bearing*, serta menurunkan biaya perawatan melalui pengambilan keputusan yang lebih cerdas dan berbasis data.

Kata kunci: perawatan prediktif, *big data*, kecerdasan buatan, data kualitas, *machine learning*.

ABSTRACT

PREDICTIVE MAINTENANCE IN PRODUCTION SYSTEM WITH BIG DATA ANALYTICS AND ANTIFICIAL INTELLIGENCE USING MACHINE CONDITIONA AND QUALITY DATA REAL TIME

By

TOTO SUHARTO

NIM: 33420002

(Doctoral Program in Industrial Engineering and Management)

The Government of Indonesia has committed to strengthening the manufacturing industry through the launch of Making Indonesia 4.0 in April 2018, with the objective of increasing productivity in the manufacturing sector, thereby enhancing Indonesia's global competitiveness and expanding its share in the global export market. The five industrial sectors prioritized, which are food and beverage, textiles, chemicals, automotive, and electronics, are expected to spearhead the implementation of Industry 4.0 technologies, such as the Internet of Things (IoT), 3D printing, advanced robotics, big data analytics, and artificial intelligence (AI).

Currently, the implementation of Industry 4.0 is well advanced in European countries, whereas Indonesia's manufacturing industry must continue to catch up. One important implementation of Industry 4.0 is smart maintenance. There are two types of maintenance practices commonly applied in manufacturing systems today: corrective maintenance and preventive maintenance. Both have shortcomings, including unexpected machine failures that cause production stoppages or premature replacement of components. Therefore, the adoption of predictive maintenance utilizing sensor data analyzed through AI technologies is necessary as part of the Industry 4.0 approach to smart maintenance.

This research aims to develop a predictive maintenance model based on the integration of heterogeneous sensor data, including machine condition data and real-time product quality information (e.g., vibration checking and radial clearance checking). The model is developed using a hybrid approach that combines machine learning (ML) and deep learning (DL), integrating statistical methods, conventional ML models, and DL architectures to improve anomaly detection and Remaining Useful Life (RUL) prediction capabilities while maintaining Overall Equipment Effectiveness (OEE) and product quality in accordance with manufacturing standards.

In addition, this research implements Explainable Artificial Intelligence (XAI) methods, specifically SHAP (SHapley Additive exPlanations), to identify feature importance across sensor variables that influence machine performance and product quality. This approach provides transparency and interpretability,

enabling engineers to better understand and trust the model's decision-making process, thereby supporting its adoption in manufacturing environments.

The research begins with a comprehensive literature review on predictive maintenance to establish the state of the art and identify theoretical gaps that inform the formulation of research problems and objectives. Subsequently, best practices in predictive maintenance will be re-evaluated within the research context. Model development starts with anomaly detection in the ball bearing production process using ML and DL methods, followed by model simplification tailored to industrial requirements.

Scientifically, this research contributes to advancing real-time predictive maintenance with the integration of heterogeneous data, which remains limited in prior studies, while delivering a model that is not only accurate but also explainable. Practically, the implementation of the proposed model is expected to reduce unplanned downtime, improve operational efficiency and OEE, maintain ball bearing product quality, and reduce maintenance costs through smarter, data-driven decision-making.

Keywords: predictive maintenance, big data, artificial intelligence, quality data, machine learning.

HALAMAN PENGESAHAN

PERAWATAN PREDIKTIF UNTUK SISTEM PRODUKSI DENGAN PENDEKATAN ANALISIS *BIG DATA* DAN KECERDASAN BUATAN MENGGUNAKAN DATA KONDISI MESIN DAN INFORMASI KUALITAS YANG *REAL TIME*

Oleh
Toto Suharto
NIM: 33420002
(Program Studi Doktor Teknik dan Manajemen Industri)

Institut Teknologi Bandung

Menyetujui
Tim Pembimbing

Tanggal 28 Agustus 2025

Ketua

Prof. Dr. Ir. Kadarsah Suryadi, DEA

Anggota

Anggota

Prof. Ir. Bermawi Priyatna Iskandar, M.Sc., Ph.D.

Prof. Dr. Ir. Bambang Riyanto Trilaksono

-

KATA PENGANTAR

Segala puji dan syukur penulis panjatkan kepada Allah SWT yang telah memberikan rahmat dan hidayah-Nya sehingga penulis dapat menyelesaikan dokumen proposal disertasi program doktor ini dengan baik. Penyusunan dokumen proposal disertasi ini merupakan syarat ujian proposal disertasi pada program studi Teknik dan Manajemen Industri (TMI) Fakultas Teknologi Industri (FTI) Institut Teknologi Bandung (ITB). Ujian proposal merupakan salah satu syarat kelulusan mahasiswa program doktoral dalam proses penyusunan disertasi.

Disertasi yang diusulkan oleh penulis berjudul “Perawatan Prediktif untuk Sistem Produksi dengan Pendekatan Analisis *Big Data* dan Kecerdasan Buatan menggunakan Data Kondisi Mesin dan Informasi Kualitas yang *Real Time*.”

Penulis mengucapkan terima kasih kepada:

1. Prof. Dr. Kadarsah Suryadi, DEA, Prof. Ir. Bermawi Priyatna Iskandar, M.Sc., Ph.D. dan Prof. Dr. Ir. Bambang Riyanto Trilaksono selaku Promotor dan Co-Promotor atas bimbingan dan masukannya yang bernilai dalam menyusun dan menyelesaikan proposal disertasi ini.
2. Khoirul Muslim, S.T, M.Sc., Ph.D. selaku Ketua Program Studi Doktor Teknik dan Manajemen Industri atas masukan dan arahannya dalam menyelesaikan proposal disertasi ini.
3. Para Dosen penguji ujian kualifikasi, ujian proposal dan seminar kemajuan yang sudah memberikan masukan yang konstruktif dan membuat proposal ini menjadi lebih baik.
4. Keluarga dan teman-teman yang selalu memberikan dukungan dan doa untuk kesuksesan menyelesaikan studi program doktor ini.

Penulis menyadari bahwa penulisan proposal ini jauh dari kata sempurna, maka penulis mengharapkan masukan untuk perbaikan disertasi ini sehingga dapat menjadi acuan untuk penelitian lanjutan dan penyelesaian disertasi.

Jakarta, 24 Agustus 2025

Toto Suharto

DAFTAR ISI

ABSTRAK	I
ABSTRACT	III
HALAMAN PENGESAHAN	V
KATA PENGANTAR.....	VI
DAFTAR ISI	VIII
DAFTAR GAMBAR DAN ILUSTRASI	X
DAFTAR TABEL	XII
DAFTAR SINGKATAN DAN LAMBANG.....	XIII
 BAB I PENDAHULUAN	 1
I.1 Latar Belakang.....	1
I.2 Perumusan Masalah	15
I.3 Tujuan Penelitian.....	15
I.4 Manfaat Penelitian	17
I.5 Batasan dan Asumsi Penelitian.....	17
I.6 Kontribusi dan Posisi Penelitian.....	18
I.6.1 Tahap Perencanaan	19
I.6.2 Rancangan dan Persiapan Penelitian	27
I.6.3 Pengembangan Model	33
I.6.4 Komparasi Model dengan Dunia Nyata.....	33
I.6.5 Aksi untuk Perbaikan Situasi	33
I.6.6 Kesimpulan dan Saran	33
I.6.7 Sistematika Penelitian	34
 BAB II TINJAUAN PUSTAKA.....	 36
II.1 Product Quality Control.....	36
II.2 Industri 4.0	36

II.3	Internet of Things	37
II.4	Big Data	37
II.5	Artificial Intelligence.....	39
II.6	Machine Learning	39
II.6.1	Deep Learning	42
II.6.2	Explainable AI dan SHAP (SHapley Additive exPlanations)	44
II.7	Perawatan Prediktif.....	46
BAB III PENGEMBANGAN MODEL.....		48
III.1	Sintesa Model State of the Art	48
III.2	Model Perawatan Prediktif untuk Sistem Produksi dengan Pendekatan Analisis Big Data dan Kecerdasan Buatan Menggunakan Data Kondisi Mesin dan Informasi Kualitas Waktu-Nyata (Usulan)	61
III.2.1	Keterkaitan Model dengan Tujuan Penelitian.....	66
III.2.2	Studi Kasus I: Proses Seleksi Algoritma	67
III.2.3	Studi Kasus II: Perbandingan Algoritma dan Integrasi Data Kualitas	68
III.2.4	Studi Kasus III: Simplifikasi dan Peluncuran Model	72
BAB IV PENGUMPULAN DAN PENGOLAHAN DATA.....		73
IV.1	Sumber Vibrasi	73
IV.2	Analisis Spektrum.....	74
IV.3	Sensor untuk mengkoleksi data	79
IV.4	Koleksi data dari mesin.....	80
BAB V ANALISIS DAN PEMBAHASAN		82
V.1	Pengolahan Data Vibrasi.....	82
V.2	Analisis Data Dengan Trend (Time-based Monitoring).....	83
V.3	Analisis Data Dengan Spektrum (Frequency-based Monitoring)	83
V.4	Model Pengembangan Perawatan Prediktif	88

DAFTAR GAMBAR DAN ILUSTRASI

Gambar I.1 Perjalanan Industri 4.0	1
Gambar I.2 Arsitektur analisis <i>big data</i>	4
Gambar I.3 Contoh kasus penerapan analisis <i>big data</i> dalam sistem produksi.	5
Gambar I.4 Studi kasus analisis <i>big data</i> . Sumber: (Cheng, Zhang, & Gao, 2019).	5
Gambar I.5 Tool aus di pada proses cutting (kiri), data pengukuran dan model yang disesuaikan (kanan).	7
Gambar I.6 Prediksi sisa waktu penggunaan (RUL) menggunakan dua model.	7
Gambar I.7 Arsitektur CPA dan <i>Health Index Hierarchy</i>	9
Gambar I.8 Sudut pandang level manajemen dan level peralatan (<i>equipment</i>).	9
Gambar I.9 <i>Factory Health Index</i> (FHI) sebelum dan sesudah perawatan katup gas.	10
Gambar I.10 Komponen-komponen <i>ball bearing</i> . Sumber: (SKF Group, 2017).	11
Gambar I.11 Proses permesinan <i>ball bearing</i> . Sumber: (SKF Group, 2017)	11
Gambar I.12 Diagram Tulang Ikan penelitian	13
Gambar I.13 Sistem pengujian <i>ball bearing</i> . Sumber: (SKF Group, 2017)	14
Gambar I.14 Skema pendekatan penelitian.....	16
Gambar I.15 Taksonomi penelitian.....	20
Gambar III.1 Model penelitian acuan	48
Gambar III.2 Diagram Alur Pengembangan Model Perawatan Prediktif.....	62
Gambar IV.1 Konversi Getaran Menjadi Sinyal Melalui Sensor Vibrasi (Predictive Maintenance and Vibration Signature Analysis II, 1997)	73

Gambar IV.2 Ilustrasi Sinyal Dalam Domain Waktu dan Domain Frekuensi (Predictive Maintenance and Vibration Signature Analysis II, 1997)	74
Gambar IV.3 Display yang ditunjukkan lewat time domain atau frequency domain (Predictive Maintenance and Vibration Signature Analysis II, 1997)	75
Gambar IV.4 Konversi Getaran Menjadi Spektrum (Signal Processing in Detail, Mobius Institute, 2016)	75
Gambar IV.5 Spektrum Normal Dari Data Sensor Vibrasi (Signal Processing in Detail, Mobius Institute, 2016)	76
Gambar IV.6 Kecepatan Dan Percepatan Dalam Spektrum (Signal Processing in Detail, Mobius Institute, 2016)	77
Gambar IV.7 Perbandingan <i>Baseline</i> Dengan Kenaikan Frekuensi 1x Dan Vibrasi Bearing (Signal Processing in Detail, Mobius Institute, 2016)	77
Gambar IV.8 Proses Enveloping Atau Demodulasi Amplitudo (Signal Processing in Detail, Mobius Institute, 2016)	78
Gambar IV.9 Cara Kerja Akselerometer	80
Gambar IV.10 Proses Koleksi Data Dari Mesin	80
Gambar IV.11 Penempatan Sensor di Mesin	81
Gambar V.1 Pengolahan Data Vibrasi	82
Gambar V.2 Contoh Tren dan Spektrum	84
Gambar V.3 Contoh <i>Looseness</i> dan <i>Envelope</i>	85

DAFTAR TABEL

Tabel I-1 Posisi penelitian	21
Tabel III-1 Pemaparan <i>State of the Art</i> penelitian (SotA) Perawatan Prediktif (PdM)	49
Tabel III-2 Pemaparan <i>State of the Art</i> penelitian (SotA) Perawatan Prediktif (PdM) (lanjutan).....	51
Tabel III-3 Pemaparan <i>State of the Art</i> penelitian (SotA) Perawatan Prediktif (PdM) (lanjutan).....	53
Tabel III-4 Pemaparan <i>State of the Art</i> penelitian (SotA) Perawatan Prediktif (PdM) (lanjutan).....	55
Tabel III-5 Pemaparan <i>State of the Art</i> penelitian (SotA) Perawatan Prediktif (PdM) (lanjutan).....	57
Tabel III-6 Sintesa model acuan yang digunakan dalam pengembangan model..	59
Tabel III-7. Keterkaitan Algoritma Kandidat dengan Tujuan Penelitian.....	66

DAFTAR SINGKATAN DAN LAMBANG


SINGKATAN	Nama	Pemakaian pertama kali pada halaman
AI	Artificial Intelligence	1
TPS	Toyota Production System	1
ARIMA	Autoregressive Integrated Moving Average	4
ANN	Artificial Neural Network	6
RUL	Remaining Useful Life	6
AMCoT	Advanced Manufacturing Cloud of Things	7
CPA	Cyber-Physical Agent	7
DHI	Device Health Index	8
FHI	Factory Health Index	8
FMEA	Failure Mode and Effects Analysis	8
HIH	Health Index Hierarchy	8
MHI	Module Health Index	8
RF	Random Forest	8
SHI	Station Health Index	8
CBM	Condition-Based Maintenance	18
CNN	Convolutional Neural Network	18
DBN	Deep Belief Network	18
DRL	Deep Reinforcement Learning	18
DT	Decision Tree	18
GAN	Generative Adversarial Network	18
OSA-CBM	Open System Architecture for Condition Based Monitoring	18
PdM	Predictive Maintenance	18
R2F	Run-to-Failure	18
RNN	Recurrent Neural Network	18
SVM	Support Vector Machine	18

SINGKATAN	Nama	Pemakaian pertama kali pada halaman
ML	Machine Learning	20
LR	Linear Regression	21
DL	Deep Learning	22
IoT	Internet of Things	23
CPD	Cyber-Physical System	25
IIoT	Industrial Internet of Things	25
BN	Bayesian Network	31
GRU	Gated Recurrent Units	31
LSTM	Long Short-Term Memory	31
SVR	Support Vector Regression	31
AE	Auto Encoder	32
PM	Preventive Maintenance	33
OEE	Overall Equipment Effectiveness	34
OGE	Overall Tool Group Efficiency	34
IPM	Intelligent Predictive Maintenance	37

Bab I Pendahuluan

I.1 Latar Belakang

Pemerintah Indonesia telah berkomitmen untuk membangun industri manufaktur yang kokoh dengan diluncurkannya *Making Indonesia 4.0* pada bulan April 2018. Program ini diharapkan dapat meningkatkan produktivitas di industri manufaktur sehingga meningkatkan daya saing Indonesia secara global dan juga mengangkat pangsa pasar ekspor global. Pemerintah dalam hal ini telah menetapkan fokus penerapan industri 4.0 di lima sektor industri yang merupakan penyumbang terbesar untuk ekspor dan penyedia kesempatan untuk tenaga kerja terbanyak. Lima sektor industri tersebut terdiri atas industri makanan dan minuman, tekstil, kimia, otomotif dan elektronika. Kelima sektor tersebut diharapkan menjadi ujung tombak dalam penerapan teknologi industri 4.0, seperti *Internet of Things* (IoT), *3D printing*, robotika maju, analisis *big data* dan kecerdasan buatan.



Gambar I.1 Perjalanan Industri 4.0

Penerapan Industri 4.0 pada kelima sektor industri diharapkan dapat menyelesaikan permasalahan pada delapan aspek seperti yang dapat dilihat pada Gambar I.1. Delapan aspek tersebut meliputi peningkatan produktivitas dalam proses produksi, mengurangi total waktu henti mesin pada utilisasi aset, meningkatkan produktivitas dengan melakukan otomasi produksi, mengurangi biaya inventaris, mengurangi biaya untuk manajemen kualitas, meningkatkan akurasi peramalan produksi, mengurangi waktu menuju pasar bagi suatu produk, dan mengurangi biaya perawatan. Studi doktoral ini akan berfokus pada empat dari delapan aspek tersebut, meliputi aspek proses, utilisasi aset, kualitas, dan layanan.


Pemerintah telah menetapkan 10 prioritas nasional dalam inisiatif *Making Indonesia 4.0* untuk merevitalisasi industri manufaktur. Beberapa prioritas nasional yang sangat berhubungan dengan tujuan studi doktoral ini yaitu membangun infrastruktur digital nasional, peningkatan kualitas SDM, membangun ekosistem inovasi dan insentif untuk investasi teknologi. Salah satu aspek dalam mendorong implementasi industri 4.0 di Indonesia adalah penerapan sistem produksi sesuai dengan metode *lean manufacturing*. Metode ini bisa menjadi mesin penggerak yang mempercepat implementasi industri 4.0 di perusahaan-perusahaan manufaktur. *Lean manufacturing* yang lahir dari *Toyota Production System* (TPS) merupakan prinsip dalam sistem produksi yang sangat memperhatikan perbaikan yang dilakukan secara terus menerus (*continuous improvement*), memanfaatkan sumber daya secara optimal dan menghilangkan kegiatan yang tidak menghasilkan nilai tambah (*waste* atau *non-value added activities*).

Prinsip-prinsip *lean manufacturing* yang diterapkan di industri manufaktur saat ini meliputi sistem tarik (hanya memproduksi dan memasok yang dibutuhkan pelanggan), menghindari kesalahan secara preventif, berorientasi kepada proses dan fleksibel, standardisasi dari proses, transparansi sehingga deviasi mudah dideteksi, dan perbaikan yang terus menerus. Perkembangan dan penerapan teknologi industri 4.0 di industri manufaktur, seperti *Internet of Things* (IoT), integrasi antara IT (*Information Technology*) dan OT (*Operation Technology*) serta sensor-sensor yang digunakan di mesin produksi yang semakin memiliki kecerdasan lokal, perusahaan manufaktur bisa mengumpulkan data-data produksi dari berbagai titik di mesin produksi ataupun dari proses produksi itu sendiri. Data-data ini kemudian bisa dimanfaatkan untuk mengoptimalkan sistem produksi sesuai *lean manufacturing*.

Terkait dengan aspek menghindari kesalahan (*fault prevention*) dalam sistem *lean manufacturing* telah diterapkan perawatan preventif (*preventive maintenance*) dengan jadwal yang teratur. Seperti yang dijelaskan oleh (Ayvaz & Alpay, 2021), perawatan preventif biasanya dilakukan dengan menggantikan komponen atau peralatan yang digunakan setelah terjadi kerusakan atau untuk jangka waktu yang sudah ditentukan. Pendekatan preventif ini memiliki kekurangan karena dua hal, mengganti peralatan yang terlalu dini sehingga mengakibatkan biaya tambahan atau terlambat mengganti peralatan sehingga terjadi kerusakan mesin yang mengakibatkan produksi berhenti. Produksi berhenti mengakibatkan kerugian pada perusahaan.

Teknologi industri 4.0 seperti kecerdasan buatan, *machine learning* dan analisis *big data*, menghasilkan sistem perawatan baru yang bersifat prediktif (*predictive maintenance*) seperti yang digunakan pada penelitian (Einabadi et al., 2019), (Traini et al., 2019), dan (Ayvaz & Alpay, 2021). Penggunaan analisis *big data* dan kecerdasan buatan digunakan untuk optimalisasi parameter dalam menjalankan mesin produksi atau penunjang pengambilan keputusan dalam manajemen kualitas produk di perusahaan manufaktur seperti yang diuraikan (Zhu et al., 2024).


Implementasi analisis *big data* saat ini pada umumnya menggunakan arsitektur seperti pada Gambar I.2, dimana data yang bersumber dari sistem produksi kemudian dikoleksi atau disimpan dalam sistem penyimpanan data seperti sistem Kafka untuk kemudian diproses menggunakan metode analisis *big data* tertentu menggunakan sistem perangkat lunak Hadoop. Hasil analisis ini kemudian ditampilkan dalam bentuk presentasi atau visualisasi kepada pengguna yang bersangkutan menggunakan aplikasi seperti perangkat lunak Tableau atau yang berbasis web. Implementasi aplikasi seperti ini dapat memberikan jawaban atas tantangan (*pain point*) yang dihadapi perusahaan manufaktur. Selanjutnya diharapkan sistem seperti ini bisa diintegrasikan dalam sistem produksi yang lebih luas lagi lingkungannya.



Gambar I.2 Arsitektur analisis *big data*.

Saat ini implementasi industri 4.0 di negara-negara Eropa sudah sangat maju, sementara industri manufaktur di Indonesia masih harus mengejar ketinggalan. Dari berbagai kasus implementasi di negara-negara Eropa, perusahaan manufaktur di Indonesia bisa belajar dan mengadopsi solusi yang sudah ada. Meskipun demikian beberapa implementasi industri 4.0 terutama yang menggunakan analisis *big data* masih terlihat secara parsial dan belum terintegrasi penuh dengan sistem produksi. Aplikasi analisis *big data* saat ini umumnya mencakup bidang perbaikan waktu siklus dalam proses produksi, analisis penyebab utama (*root cause analysis*) atau pendeteksian anomali (*anomaly detection*) dalam sistem manajemen kualitas,

optimasi kapasitas dalam bidang logistik ataupun pengurangan waktu pengetesan suatu produk. Contoh kasus implementasi analisis *big data* umumnya bertahap dari metode deskriptif, diagnostik, prediktif baru mengarah ke pendekatan kognitif dan otomatis seperti diilustrasikan pada Gambar I.3.



Gambar I.3 Contoh kasus penerapan analisis *big data* dalam sistem produksi.


Sebagai contoh, Gambar I.4 menampilkan studi kasus dengan menggunakan analisis *big data* untuk mengidentifikasi parameter yang sangat berpengaruh dalam proses produksi. Setelah melakukan identifikasi, langkah berikutnya adalah membuat analisis penyebab utama terjadinya produk yang rusak serta memberikan rekomendasi perbaikan parameter terkait. Namun, proses tersebut masih dilakukan secara manual dan belum terintegrasi dengan sistem produksi.

PRODUCT & DATA	METHODOLOGY	RESULTS
Pressure, speed, and current data of the bearing production line.	Using ARIMA Model, LSTM Neural Networks, and ARIMA-LSTM Prediction Model	

Gambar I.4 Studi kasus analisis *big data*. Sumber: (Cheng, Zhang, & Gao, 2019).


Penelitian yang dilakukan (Einabadi, Baboli, & Ebrahimi, 2019) menjelaskan bahwa perawatan prediktif dapat dilakukan dengan menggunakan data sensor yang dianalisis menggunakan kecerdasan buatan. Model prediktif yang dihasilkan dapat mengoptimalkan penjadwalan perawatan dan memperlihatkan korelasi terhadap biaya perawatan yang harus dikeluarkan. Waktu yang dibutuhkan untuk perawatan rutin didapatkan dengan memperbarui data dari mesin di lantai pabrik menggunakan strategi baru yang bernama perawatan preventif dinamis (*Dynamic Preventive Maintenance* seperti yang disampaikan (Einabadi, Baboli, & Ebrahimi, 2019). Data atau informasi dari mesin di lantai pabrik biasanya didapatkan dari sensor-sensor yang terpasang di mesin. Tantangannya adalah menemukan prognosis untuk dapat memprediksi kerusakan berikutnya pada mesin dan melakukan perbaikan sebelum waktu yang diprediksi mesin akan rusak. Keuntungan dari perawatan secara prediktif yaitu mengurangi perawatan yang tidak diharapkan, meningkatkan waktu penggunaan suku cadang dengan pemanfaatan penggunaan suku cadang semaksimal mungkin, mengurangi atau menghindari kerusakan sistem (*shutdown*) dengan memonitor dan menganalisis kesalahan mesin, dan meningkatkan ketersediaan waktu produksi (Einabadi, Baboli, & Ebrahimi, 2019).

Penelitian (Yan, Meng, Lu, & Li, 2017) mengedepankan kemajuan pemrosesan *big data* di industri dan mengeksplorasi perawatan prediktif berbasis pemrosesan *big data*. Kerangka kerja yang diusulkan berguna untuk menstruktur informasi yang heterogen dari beberapa sumber, melakukan karakterisasi struktur data dengan mempertimbangkan ciri-ciri ruang dan waktu (*spatial temporal*), pemodelan faktor yang tidak muncul yang membuat proses produksi lebih transparan dengan mengimplementasikan perawatan prediktif di era industri 4.0. Efektivitas sistem yang diusulkan telah divariasikan dengan menganalisis sumber data yang heterogen untuk memprediksi RUL dari komponen-komponen kunci yang ada di mesin.



Gambar I.5 Tool aus di pada proses cutting (kiri), data pengukuran dan model yang disesuaikan (kanan).


Gambar I.5 menunjukkan model yang disesuaikan dengan data-data yang diukur. Pada model prediksi I data vibrasi digunakan untuk memprediksi RUL dari *cutter* dengan menggunakan model ANN dan 10 fitur statistik. Maka, dapat terlihat terjadinya fluktuasi yang besar pada periode prediksi terutama antara menit ke 146 dan 149. Pada model prediksi II selain menggunakan 10 fitur statistik, pendekatan ini menggabungkan fitur daya. Dibandingkan model prediksi I, analisis menggunakan sumber data yang heterogen memberikan kurva yang lebih baik. Hasil penelitian ini menunjukkan model prediksi II dengan berbagai sumber data yang heterogen dapat memberikan hasil prediksi yang lebih akurat, seperti terlihat dalam Gambar I.6.



Gambar I.6 Prediksi sisa waktu penggunaan (RUL) menggunakan dua model.


Studi kasus ini dilakukan untuk memprediksi waktu penggunaan yang tersisa (RUL) dari komponen kunci dari peralatan mesin dengan menganalisis data dari sumber yang heterogen. Hasil dari penelitian menunjukkan pendekatan yang diusulkan memiliki kinerja yang lebih baik dalam menentukan RUL dibandingkan metode tradisional menggunakan informasi dari satu sumber. Di lain pihak metode *machine learning* yang tradisional seperti ANN masih memiliki peranan yang penting dalam industri 4.0 untuk kondisi-kondisi tertentu. Hasil penelitian ini memberikan indikasi bahwa sumber data yang heterogen dapat memberikan solusi baru untuk perawatan prediktif, penjadwalan dan optimasi proses produksi untuk menghemat energi.

Masalah perbaikan prediktif secara tradisional saat ini hanya diimplementasikan untuk satu peralatan atau mesin dan tidak untuk memonitor semua peralatan secara keseluruhan untuk satu pabrik. Untuk pabrik yang besar alokasi dari sumber daya akan rumit karena melibatkan peralatan atau mesin yang berjumlah besar. Solusi yang diusulkan oleh (Chiu, Cheng, & Huang, 2017) adalah perawatan prediktif untuk seluruh pabrik. Untuk itu dibutuhkan infrastruktur dan platform untuk komunikasi dan pengolahan data yang sangat baik, diagnosa mesin dan prognosis kesalahan yang efektif, struktur indeks kesehatan mesin yang bisa dikelola dengan baik dipandang dari keseluruhan pabrik. Sistem perbaikan prediktif yang pintar untuk keseluruhan pabrik atau *intelligent predictive maintenance* (IPM) diusulkan dengan mengimplementasikan *cyber-physical agent* (CPA) dan *advanced manufacturing cloud of things* (AMCoT) untuk memenuhi persyaratan Industri 4.0 (Cheng, Zhang, & Gao, 2019), yaitu *baseline predictive maintenance* (BPM) (Chiu, Cheng, & Huang, 2017).



Gambar I.7 Arsitektur CPA dan *Health Index Hierarchy*.

Sebagai contoh kasus dari HIH ditampilkan di Gambar I.8 dan Gambar I.9. Seorang ahli dalam bidang ini mendefinisikan generator RF, pengontrol suhu, MFC, dan katup gas seperti digambarkan dalam Gambar I.8 menjadi alat yang dinamakan PECVD (CVD 1) melalui FMEA (*failure mode and effects analysis*). Dari sudut pandang CVD 1-1 sebelum perbaikan katup gas DHI dari empat alat di atas adalah 0.21, 0.87, 0.84 dan 0.93 seperti di tabel (a) pada Gambar I.9. Sedangkan MHI dari modul vakum, suhu dan RF adalah 0.21, 0.84 dan 0.93. Sehingga EHI dari CVD 1-1 menjadi 0.21.



Gambar I.8 Sudut pandang level manajemen dan level peralatan (*equipment*).

Di tabel (a) pada Gambar I.9 komponen-komponen terkait memiliki SHI berikut 0.86, 0.75, 0.91, 0.21, 0.77 dan 0.89. Sehingga FHI sistem menjadi 0.21 (merah), karena DHI dari katup gas merupakan yang paling rendah 0.21 (merah), sehingga katup gas harus segera mendapatkan perawatan. Setelah perbaikan katup gas memiliki nilai DHI 0.96. Sehingga DHIs, MHIs, EHIs baru ditunjukkan di tabel (b) pada Gambar I.9, dengan FHI menjadi 0.75 karena DIF dari stasiun tersebut memiliki SHI yang paling rendah yaitu 0.75.

(a) Before Repair of Throttle Valve												
FHI	0.21											
SHI	TEX	DIF	PSG	CVD 1							PRT	FCT
	0.86	0.75	0.91	0.21							0.77	0.89
EHI	...	...	...	CVD 1-1			CVD 1-2	CVD 1-3	CVD 1-4	...	...	
0.21				0.77	0.94	0.88						
MHI				Vacuum		Temp.	RF	...	...			...
				0.21		0.84	0.93					
DHI				Throttle Valve		MFC	Temp. Controller	RF Generator	...			...
	0.21		0.87	0.84	0.93							


(b) Before Repair of Throttle Valve												
FHI	0.75											
SHI	TEX	DIF	PSG	CVD 1							PRT	FCT
	0.86	0.75	0.91	0.77							0.77	0.89
EHI	...	...	...	CVD 1-1			CVD 1-2	CVD 1-3	CVD 1-4	...	...	
0.84				0.77	0.94	0.88						
MHI				Vacuum		Temp.	RF	...	...			...
				0.96		0.84	0.93					
DHI				Throttle Valve		MFC	Temp. Controller	RF Generator	...			...
	0.96		0.87	0.84	0.93							

Gambar I.9 *Factory Health Index* (FHI) sebelum dan sesudah perawatan katup gas.

Objek penelitian yang diusulkan adalah produksi *ball bearing* yang memiliki komponen seperti *ring*, *ball* dan *cage* seperti terlihat dalam Gambar I.10. Sebelum dilakukan perakitan *bearing*, komponen *ring* akan melalui proses permesinan (*machining*) seperti *grinding* dan *honing* yang terlihat dalam Gambar I.11. Apabila perawatan prediktif dapat dilakukan untuk proses permesinan, maka perawatan yang tidak terjadwal dapat diturunkan, waktu penggunaan perkakas dapat dimaksimalkan, mengurangi produksi yang terhenti karena kerusakan perkakas dan mengurangi masalah kualitas pada produk.



Gambar I.10 Komponen-komponen *ball bearing*. Sumber: (SKF Group, 2017)




Gambar I.11 Proses permesinan *ball bearing*. Sumber: (SKF Group, 2017)

Peneliti kemudian melakukan observasi lapangan pada salah satu channel produksi objek penelitian. Berdasarkan hasil observasi lapangan yang dilakukan oleh peneliti, maka didapatkan beberapa tantangan dan peluang dalam menerapkan perawatan prediktif pada objek penelitian, yaitu sebagai berikut.

1. Terdapat beberapa kasus kesalahan pemotongan perkakas saat proses produksi sehingga mengakibatkan pemeliharaan yang tidak terencana. Hal ini menimbulkan kerusakan *cutting tool*, masalah kualitas produk, peningkatan biaya produksi, dan peningkatan biaya pemeliharaan.
2. Suku cadang mesin tidak digunakan secara maksimal akibat kerusakan tooling yang terjadi sehingga efisiensi mesin menurun.
3. Terjadinya kerusakan dan mesin berhenti pada lini produksi secara tiba-tiba sehingga merusak prediksi yang telah dilakukan.


Tingkat kerusakan pada produk ball bearing yang dihasilkan oleh objek penelitian saat ini masih cukup tinggi. Hal tersebut menjadi akar masalah pada penelitian ini yaitu tingginya tingkat penolakan produk karena tidak sesuai dengan standar kualitas. Peneliti kemudian melakukan analisis tulang ikan dengan menggunakan diagram tulang ikan seperti pada Gambar I.12. Analisis dilakukan pada enam aspek yaitu pekerja, metode, mesin, pengukuran, material, dan lingkungan. Pada aspek pekerja, saat ini pelatihan yang dilakukan kepada operator mesin masih kurang memadai sehingga operator tidak memiliki pengetahuan mengenai kualitas produk. Pada aspek metode, saat ini perancangan desain proses dan produk masih buruk, serta manajemen kualitas yang diterapkan belum efektif dalam rangka meningkatkan kualitas produk. Pada aspek mesin, saat ini mesin yang digunakan sudah cukup tua atau usang, dimana sering terjadi masalah pada perkakas, dan keluar dari parameter permesinan yang ditetapkan sebelumnya. Pada aspek pengukuran, saat ini terdapat beberapa kesalahan dalam menggunakan peralatan pengujian sehingga perlu dilakukan perbaikan metode pengukuran kualitas produk. Pada aspek material, saat ini masih terdapat masalah dalam penanganan material serta terdapat kemungkinan produk cacat dari vendor atau pemasok material. Pada aspek lingkungan, saat ini kontrol suhu yang dilakukan masih belum akurat serta masih terdapat debu atau kotoran pada lingkungan kerja.




Gambar I.12 Diagram Tulang Ikan penelitian

Berdasarkan hasil analisis tulang ikan pada Gambar I.12, penelitian ini akan berfokus pada penyelesaian aspek mesin dan pengukuran. Penelitian yang diusulkan untuk program studi doktor ini akan mengembangkan model prediktif yang sudah dikembangkan tersebut dengan menambahkan masukan seperti informasi produksi, jumlah dan tipe produk yang dihasilkan serta informasi kualitas dari produk yang dihasilkan secara waktu nyata.

Implementasi perawatan prediktif pada produksi *bearing* saat ini hanya berfokus pada penggantian perkakas yang bisa mengakibatkan kerusakan pada mesin dan menghentikan produksi, atau kerusakan pada komponen *ring* yang diakibatkan oleh proses permesinan dengan perkakas yang sudah tidak bagus (*tool wear*). Sementara, data-data kualitas hasil pengetesan produk akhir *bearing* seperti *Vibration Checking* dan *Radial Clearance Checking* seperti terlihat dalam Gambar I.13 belum dimasukkan sebagai parameter dalam model perawatan prediktif yang dilakukan (Einabadi, Baboli, & Ebrahimi, 2019). Untuk memperbaiki model prediksi bisa memanfaatkan hasil penelitian yang sudah dilakukan oleh (Yan, Meng, Lu, & Li, 2017) terkait pengolahan sumber informasi lebih dari satu sumber yang heterogen. Sehingga prediksi perawatan menjadi lebih akurat.



Vibration checking



Radial clearance checking

Gambar I.13 Sistem pengujian *ball bearing*. Sumber: (SKF Group, 2017)

Dari sini disimpulkan perlu dilakukan penelitian baru terhadap perbaikan sistem perawatan prediktif yang sudah ada dengan menambahkan parameter baru dari hasil proses pengetesan produk. Data-data kualitas dari hasil pengetesan seperti *vibration* dan *clearance check* bisa menjadi perbaikan sistem perawatan prediktif penggantian perkakas untuk proses permesinan yang dilakukan untuk komponen ring. Lebih jauh lagi penelitian ini bisa mengembangkan sistem perawatan yang konvensional dengan fokus pada level komponen atau satu mesin menjadi perawatan untuk satu lini produksi dengan menerapkan hasil penelitian (Chiu, Cheng, & Huang, 2017). Untuk itu diperlukan arsitektur sistem perawatan prediktif yang lebih efektif untuk memonitor status kesehatan dari satu mesin menjadi status kesehatan seluruh mesin (satu lini produksi atau satu pabrik).

I.2 Perumusan Masalah

Dengan mempertimbangkan aspek-aspek di atas yang terkait dengan penerapan teknologi industri 4.0 dalam industri manufaktur yang berbasis *lean manufacturing* pada proposal studi doktoral ini diajukan perumusan permasalahan sebagai berikut:


1. Bagaimana pengembangan model perawatan prediktif menggunakan integrasi data sensor heterogen (data sensor mesin dan informasi kualitas produk secara waktu nyata) dengan pendekatan *machine learning* dan *deep learning* dapat mengurangi waktu henti yang tidak terencana dan meningkatkan *Overall Equipment Effectiveness (OEE)* pada produksi *ball bearing*?
2. Bagaimana model *hybrid machine learning* dan *deep learning* (kombinasi metode statistik, ML tradisional, dan DL) dapat mengoptimalkan deteksi anomali dan prediksi *Remaining Useful Life (RUL)* dengan tetap mempertahankan tingkat kualitas produk (*vibration checking* dan *radial clearance checking*) pada standar spesifikasi?
3. Bagaimana penerapan metode *explainable artificial intelligence (XAI)*, khususnya SHAP (*SHapley Additive exPlanations*), dapat digunakan untuk mengidentifikasi kepentingan fitur dan memberikan transparansi terhadap proses pengambilan keputusan model, sehingga hasil model lebih mudah dipahami dan berpotensi diadopsi oleh perekayasa dan praktisi di lingkungan industri manufaktur?

I.3 Tujuan Penelitian

Dengan perkembangan teknologi di bidang *lean manufacturing* terutama dengan penggunaan teknologi industri 4.0 serta penerapan analisis *big data* dan kecerdasan buatan, penelitian ini diharapkan menghasilkan:

1. Mengembangkan model perawatan prediktif berbasis data sensor vibrasi, menggunakan enam algoritma *machine learning* dan *deep learning* (XGBoost, CNN-LSTM, TCN, BiLSTM-Attention, GRU, ARIMA-LSTM hybrid) untuk deteksi anomali dan prediksi *Remaining Useful Life (RUL)* pada proses produksi ball bearing dengan target akurasi $\geq 95\%$ dan inference latency $< 10\text{ms}$ untuk implementasi waktu nyata.

2. Mengintegrasikan data kondisi mesin (sinyal vibrasi, suhu, putaran mesin) dengan informasi kualitas produk (*vibration checking* dan *radial clearance checking*) secara waktu nyata untuk meningkatkan akurasi prediksi dibandingkan dengan model saat ini yang hanya menggunakan satu sumber data, dengan target peningkatan akurasi 15-20% sesuai dengan penelitian Yan et al. (2017).
3. Memberikan analisis *explainability* menggunakan *SHAP* (*SHapley Additive exPlanations*) untuk mengidentifikasi kepentingan fitur dan transparansi pengambilan keputusan dari model yang dikembangkan, sehingga meningkatkan kepercayaan dan tingkat adopsi di lingkungan industri manufaktur.



Gambar I.14 Skema pendekatan penelitian

Gambar I.14 menunjukkan skema pendekatan yang akan dilakukan pada penelitian ini. Dimana tujuan khusus dari penelitian ini adalah mengembangkan sistem perawatan prediktif yang pintar dan tangguh dalam produksi yang memakai proses permesinan seperti produksi *ball bearing* dengan mengombinasikan analisis sensor data menggunakan *big data* dan anomali data kualitas hasil pengecekan produk untuk mengurangi kerusakan produk karena perkakas yang aus (*tool wear*) dan mengurangi produksi yang berhenti kerusakan mesin yang tiba-tiba sebelum perawatan yang terjadwal.

I.4 Manfaat Penelitian

Berikut merupakan kontribusi yang diharapkan dari penelitian ini.

1. Memberikan contoh kasus implementasi analisis *big data* dan kecerdasan buatan dalam sistem produksi dalam meningkatkan produktivitas dan daya saing.
2. Hasil dari penelitian ini yang berupa sistem dengan menggunakan perangkat lunak dan perangkat keras dapat menjadi contoh bagi implementasi analisis *big data* dan kecerdasan buatan dalam memperbaiki sistem perawatan prediktif yang sudah ada.
3. Sistem perawatan yang prediktif dalam produksi yang menggunakan proses permesinan dapat menjadi dasar untuk sistem perawatan prediktif dalam proses produksi yang berbeda (tidak hanya untuk produksi berbasis permesinan).

I.5 Batasan dan Asumsi Penelitian

Penelitian ini dibatasi dengan hanya mencakup hal-hal yang berhubungan dengan.

1. Sistem produksi yang menggunakan proses permesinan seperti proses *grinding* dalam produksi *ball bearing*.
2. Penelitian tidak untuk menghasilkan perangkat lunak atau keras yang baru. Sebagian besar perangkat yang akan digunakan merupakan perangkat yang sudah ada. Dalam proses penelitian, perangkat lunak dan keras akan diintegrasikan sesuai kebutuhan.
3. Model analisis menggunakan metode-metode analisis *big data* yang sudah ada, maupun pendekatan kecerdasan buatan *machine learning* dan *deep learning* yang sudah dipakai di bidang lain.

Sedangkan, asumsi yang digunakan dalam penelitian ini adalah sebagai berikut:

1. Sensor vibrasi, suhu, dan putaran mesin dipasang dengan baik dan sudah dikalibrasi pada mesin produksi ball bearing (OR1 dan OR2).
2. Data quality check (*vibration checking* dan *radial clearance checking*) tersedia secara waktu nyata dan dapat diakses melalui sistem informasi manufaktur.

3. Mesin produksi beroperasi dalam jangkauan operasi normal sesuai dengan spesifikasi teknis yang ditetapkan oleh perusahaan (*SKF system*).
4. Data historis dari perawatan terjadwal dan waktu henti yang tidak terencana tersedia untuk keperluan validasi dan *analisis manfaat-biaya*.
5. Infrastruktur komputasi (*GPU cloud* atau *on-premise server*) tersedia untuk pelatihan dan peluncuran model *machine learning* dan *deep learning*.
6. Proses permesinan *grinding* pada *ball bearing* memiliki karakteristik degradasi yang dapat dimodelkan menggunakan pendekatan *machine learning* berbasis data.

I.6 Kontribusi dan Posisi Penelitian

1. Pengembangan sistem perawatan prediktif yang menggunakan informasi dari sumber yang heterogen, dalam hal ini dari data-data sensor di mesin dan data kualitas hasil produksi yang bisa diakses secara waktu nyata.
2. Pengolahan data menggunakan analisis *big data* dan kecerdasan buatan dengan metode *machine learning* untuk mendapatkan sistem perawatan yang lebih akurat.
3. Sistem perawatan prediktif yang dapat memberikan transparansi terhadap proses pengambilan keputusan model, sehingga hasil model lebih mudah dipahami dan berpotensi diadopsi oleh perekayasa dan praktisi di lingkungan industri manufaktur

Untuk mendapatkan hasil penelitian yang terstruktur, diperlukan metode penelitian yang mendukung. Dalam melakukan penelitian ini metode penelitian akan direncanakan menggunakan:

1. Studi literatur mengenai perkembangan teknologi di bidang industri 4.0, yang terdiri atas analisis *big data*, *lean manufacturing*, dan masa depan industri manufaktur.
2. Observasi lapangan di industri manufaktur sebagai contoh sektor otomotif untuk mendapatkan data-data dan melakukan analisis dengan konsep-konsep yang nantinya akan dikembangkan untuk mewujudkan sistem perawatan prediktif yang lebih baik.

3. Meneliti sistem perawatan prediktif yang sudah diterapkan di industri manufaktur dan melakukan integrasi dengan sistem penjaminan mutu.
4. Melakukan pengembangan model perawatan prediktif yang mendeteksi anomali dengan metode *machine learning*.
5. Melakukan implementasi model perawatan prediktif dengan menggunakan kecerdasan buatan pada studi kasus produksi *ball bearing* dengan mengintegrasikan data-data kualitas hasil produksi.

I.6.1 Tahap Perencanaan

Tahap perencanaan dimulai dengan melakukan identifikasi permasalahan melalui studi literatur, melakukan perumusan metode *state of the art* dari penelitian sebelumnya, melakukan perumusan masalah dan tujuan penelitian, menetapkan ruang lingkup (batasan dan asumsi penelitian) dan metode penelitian yang sesuai, serta mendapatkan pemahaman mengenai objek kajian penelitian dengan melakukan observasi lapangan. Identifikasi masalah dan perumusan *state of the art* penelitian dilakukan dengan melakukan studi literatur penelitian terbaru mengenai penerapan *big data*, *machine learning*, dan kecerdasan buatan pada perawatan prediktif.

Perkembangan terbaru penelitian secara detail dapat dilihat pada Tabel III-1. Rumusan masalah penelitian didapatkan dari celah teori (*theory gap*) berdasarkan penelitian sebelumnya. Berdasarkan studi literatur yang dilakukan, maka dapat dipetakan taksonomi penelitian yang dapat dilihat pada Gambar I.4. Posisi penelitian mengenai perawatan prediktif dapat dilihat pada Tabel I-1 dan Gambar I.15. Berdasarkan pemetaan penelitian yang dilakukan, maka belum ada penelitian mengenai perawatan prediktif yang menggunakan data kondisi mesin dan informasi kualitas dengan pendekatan analisis *big data* dan kecerdasan buatan serta dilakukan secara *waktu nyata*. Maka, penelitian ini akan mengembangkan model dan sistem perawatan prediktif yang berbasis hasil penelitian (SharCa), (Ran, Zhou, Lin, Wen, & Deng, 2019), (Chiu, Cheng, & Huang, 2017), dan (Yan, Meng, Lu, & Li, 2017). Dalam penelitian ini model akan diberikan *input* tambahan seperti data produk yang diproduksi serta informasi data kualitas dari produk yang didapatkan secara waktu

nyata dan dianalisis menggunakan teknologi *big data* dan kecerdasan buatan. Metoda kecerdasan buatan yang akan digunakan adalah metode *machine learning* dan *deep learning* seperti yang diuraikan oleh (Serradilla, Zugasti, & Zurutuza, 2022).

Taksonomi Penelitian			
Arsitektur Sistem	OCA-CBM	<i>Cloud-enhanced</i>	<i>Maintenance 4.0</i>
Tujuan	<i>Cost minimization</i>	<i>Reliability maximization</i>	<i>Multi-objectives</i>
Pendekatan	<i>Knowledge</i>	<i>Traditional</i>	<i>Deep Learning</i>

Gambar I.15 Taksonomi penelitian

Tabel I-1 Posisi penelitian

Aspek Penelitian	Penelitian Terdahulu	Gap/Keterbatasan	Kontribusi Penelitian Ini
Sumber Data	Data satu sumber (hanya sensor vibrasi) — Einabadi et al. (2019), Traini et al. (2019), Marani et al. (2020), Ayvaz & Alpay (2021), Cardona et al. (2021)	Belum mengintegrasikan data kualitas produk sebagai input model prediktif, sehingga informasi dari kontrol kualitas tidak dimanfaatkan untuk deteksi kerusakan preventif	Data heterogen multi-sumber: Integrasi data sensor mesin (vibrasi, sensor, putaran mesin) dengan data kualitas produk (<i>vibration checking</i> , <i>radial clearance checking</i>) secara waktu nyata untuk meningkatkan akurasi prediksi 15-20% (Yan et al., 2017)
Mode Operasi	<i>Batch/offline processing</i> dengan data historis — Yan et al. (2017), Carvalho et al. (2019), Lee et al. (2019), Lindström et al. (2017), Ben Ali et al. (2015)	Implementasi waktu nyata untuk keputusan perawatan masih terbatas; sebagian besar sistem masih menggunakan analisis data historis tanpa kapabilitas untuk pengambilan keputusan langsung	Implementasi waktu nyata dengan target waktu inferensi <10ms untuk peluncuran di perangkat tertanam, memungkinkan aksi perawatan langsung berdasarkan kondisi aktual mesin
Pendekatan Model	Model tunggal atau komparasi terbatas (2-3 algoritma) — Ayvaz & Alpay (2021): ANN+SVM; Cui et al. (2022): ANN+SVM+k-NN; Ahmed et al. (2023): SVM+k-NN+Auto-encoder; Marani et al. (2020): ANFIS saja	Belum ada evaluasi komprehensif berbagai model (ML tradisional vs <i>deep learning</i> vs gabungan) pada satu studi kasus yang sama, sehingga pemilihan model kurang optimal	Pendekatan model gabungan : Evaluasi komparatif 6 algoritma: (1) XGBoost (basis ML tradisional), (2) CNN-LSTM (Khorram et al., 2020), (3) TCN dan <i>Graph Fusion</i> (Li et al., 2025), (4) <i>BiLSTM-Attention</i> (Huang et al., 2025), (5) GRU, (6) <i>ARIMA-LSTM hybrid</i> (Hamiane et al., 2024), untuk menemukan model

Aspek Penelitian	Penelitian Terdahulu	Gap/Keterbatasan	Kontribusi Penelitian Ini
			optimal dengan perbandingan yang komprehensif
<i>Explainability dan Interpretability</i>	Model <i>black-box</i> tanpa <i>explainability</i> . Sebagian besar penelitian ML/DL tidak menyediakan analisis kepentingan fitur atau transparansi keputusan (Serradilla et al., 2022; Hafeez et al., 2021; Nguyen et al., 2019)	Personil perawatan kesulitan memahami dan mempercayai keputusan model, mengakibatkan tingkat adopsi rendah dan perlawanan terhadap sistem PdM berbasis AI	Analisis <i>SHAP</i> (<i>SHapley Additive exPlanations</i>) (Bengherbia et al., 2024; Mosca et al., 2022; Bao et al., 2025) untuk: (1) Urutan kepentingan fitur global, (2) Analisis kontribusi fitur pada kerusakan spesifik, (3) Identifikasi penyebab kesalahan klasifikasi, sehingga meningkatkan kepercayaan dan transparansi
Integrasi PdM dengan kontrol kualitas	PdM dan kontrol kualitas dianggap sebagai sistem terpisah. Lindström et al. (2017, 2019): membahas kebutuhan integrasi tetapi tidak mengimplementasikan; Chiu et al. (2017): fokus pada tingkatan indeks kesehatan tanpa integrasi data kualitas	Belum ada umpan balik tertutup dari hasil pemeriksaan kualitas (<i>vibration test</i> , <i>clearance test</i>) ke pengambilan keputusan perawatan; masalah kualitas yang terketeksi setelah produksi tidak digunakan untuk perawatan prediktif	Integrasi sirkuit tertutup: Data kualitas (<i>vibration checking</i> , <i>radial clearance checking</i>) sebagai tambahan fitur prediktif untuk deteksi dini kerusakan sebelum kerusakan produk terjadi, menghasilkan sinergi antara PdM dan sistem kontrol kualitas
Dataset & Validasi	Dataset publik (CWRU, IMS, PRONOSTIA, PHM) —	Validasi pada industri manufaktur riil dengan	Implementasi industri langsung pada produksi <i>ball bearing</i> riil (mesin OR1 dan

Aspek Penelitian	Penelitian Terdahulu	Gap/Keterbatasan	Kontribusi Penelitian Ini
	Serradilla et al. (2022), Ran et al. (2019): studi literatur menggunakan dataset publik; Khorram et al. (2020): CWRU dataset; Li et al. (2025): IMS bearing dataset	batasan-batasan produksi masih terbatas; Celah antara performa akademik dan pemakaian di industri masih besar	OR2) dengan: (1) Validasi antar mesin untuk generalisasi, (2) Pengujian ketahanan dengan kondisi operasi yang bervariasi, (3) Analisis manfaat-biaya dibandingkan perawatan terencana
Gabungan pendekatan statistik dan AI	Statistik murni (ARIMA, Kalman Filter) atau <i>deep learning</i> murni (CNN, LSTM, GRU) — Ben Ali et al. (2015): ANN murni; Cheng et al. (2019): ARIMA/LSTM murni; Traini et al. (2019): ANN/DT murni	Metode statistik tradisional tidak dapat menangkap pola nonlinear; DL murni memerlukan data yang besar dan kurang dapat diterjemahkan keluarannya; tidak ada sinergi antara statistik fundamental dan kekuatan DL.	Gabungan ARIMA-LSTM (Hamiane et al., 2024) yang menggabungkan: (1) ARIMA untuk tren linear dan komponen musiman, (2) LSTM untuk variabel waktu yang non-linear dan kompleks, untuk mencapai $R^2=0,99$ dengan $MSE=0,0018$
Analisis domain waktu multi-skala	Analisis domain waktu skala tunggal. Sebagian besar penelitian menggunakan ukuran jendela tetap atau area deteksi tunggal (Ayvaz & Alpay, 2021; Ahmed et al., 2023; Cui et al., 2022)	Pola degradasi bearing terjadi pada beberapa skala waktu (transien jangka pendek dan tren jangka panjang), namun model yang ada saat ini hanya mampu menangkap satu resolusi temporal.	TCN dengan <i>Graph Fusion</i> (Li et al., 2025; Bai et al., 2025): (1) <i>Dilated convolution</i> untuk menjangkau area deteksi multi-skala, (2) <i>Graph fusion</i> untuk merepresentasikan dependensi spasial-temporal, (3) Jalur multi-resolusi paralel untuk menangkap pola secara lebih komprehensif.

Aspek Penelitian	Penelitian Terdahulu	Gap/Keterbatasan	Kontribusi Penelitian Ini
<i>Attention Mechanism</i> untuk pemilihan fitur	Rekayasa fitur manual atau tanpa <i>attention</i> . Metode ML tradisional (XGBoost, SVM, k-NN) membutuhkan fitur hasil ekstraksi manual (<i>RMS, kurtosis, crest factor</i>); model CNN-LSTM murni tanpa mekanisme <i>attention</i> (Khorram et al., 2020).	Rekayasa fitur manual memerlukan banyak tenaga dan keahlian domain; model tanpa <i>attention</i> memperlakukan semua langkah waktu secara sama, sehingga ciri kerusakan penting dapat terlewat.	BiLSTM dengan <i>Hierarchical Improved Fusion Attention</i> (Huang et al., 2025) yang secara otomatis mempelajari: (1) Posisi temporal yang paling kritis, (2) Fitur yang paling berkontribusi pada deteksi kerusakan, (3) Pembobotan fitur yang adaptif sesuai kondisi operasi.
Konsiderasi <i>Edge Deployment</i>	Hanya berbasis <i>cloud</i> . Cheng et al. (2019): koordinasi <i>edge–cloud</i> tetapi masih berfokus pada pemrosesan di <i>cloud</i> ; Hafeez et al. (2021): <i>edge intelligence</i> namun belum mengatasi keterbatasan sumber daya untuk model DL.	Model <i>deep learning</i> (CNN-LSTM, <i>BiLSTM-Attention</i>) memiliki biaya komputasi dan penggunaan memori yang tinggi, sehingga kurang sesuai untuk perangkat <i>edge</i> dengan sumber daya terbatas.	Arsitektur GRU yang lebih ringan untuk deployment di edge, dengan: (1) Parameter 33% lebih sedikit dibanding LSTM, (2) Waktu inferensi lebih cepat, (3) Teknik kompresi model (<i>pruning, quantization</i>) untuk <i>deployment</i> pada Raspberry Pi/Jetson Nano.
Analisis Manfaat-Biaya	Hanya dari sisi kinerja teknis. Mayoritas penelitian hanya melaporkan <i>accuracy, precision, recall</i> tanpa justifikasi ekonomi. (Serradilla et al., 2022; Khorram et al.,	Tanpa analisis manfaat-biaya, sulit untuk justifikasi ROI dari implementasi PdM; Keputusan manajemen membutuhkan metrik ekonomi, tidak hanya akurasi teknis.	Analisis manfaat-biaya yang komprehensif: (1) Penurunan total biaya perawatan sebesar 20–30% (Chiu et al., 2017; Einabadi et al., 2019), (2) Pengurangan waktu henti tidak terencana,

Aspek Penelitian	Penelitian Terdahulu	Gap/Keterbatasan	Kontribusi Penelitian Ini
	2020; Li et al., 2025; Huang et al., 2025)		(3) Optimalisasi penggunaan suku cadang, (4) Pengukuran peningkatan OEE.

Berdasarkan Tabel I-1, kebaruan utama penelitian ini terletak pada lima aspek fundamental yang membedakannya dari penelitian-penelitian sebelumnya.

Pertama, integrasi data heterogen dari berbagai sumber yang menggabungkan data kondisi mesin (sinyal getaran, suhu, putaran mesin) dengan informasi kualitas produk (pemeriksaan getaran dan pemeriksaan kelonggaran radial) secara waktu nyata. Pendekatan ini berbeda dengan penelitian sebelumnya yang umumnya hanya menggunakan data sensor tunggal (Einabadi dkk., 2019; Traini dkk., 2019; Marani dkk., 2020; Ayvaz & Alpay, 2021). Integrasi ini memungkinkan umpan balik tertutup antara sistem kendali mutu dan perawatan prediktif, sehingga anomali dapat dideteksi lebih awal sebelum mengakibatkan produk cacat.

Kedua, implementasi pendekatan multi-model hibrid dengan evaluasi komparatif enam arsitektur pembelajaran mesin dan pembelajaran mendalam (XGBoost, CNN-LSTM, TCN, BiLSTM-Attention, GRU, ARIMA-LSTM hibrid) untuk menemukan model optimal bagi industri bantalan bola. Evaluasi dilengkapi dengan perbandingan ketat terhadap berbagai metrik (akurasi, presisi, recall, skor F1, latensi inferensi, kebutuhan memori). Penelitian sebelumnya umumnya hanya menggunakan satu hingga tiga algoritma tanpa perbandingan yang komprehensif (Ayvaz & Alpay, 2021; Cui dkk., 2022; Ahmed dkk., 2023).

Ketiga, penerapan analisis SHAP (*SHapley Additive exPlanations*) untuk kecerdasan buatan yang dapat dijelaskan. Analisis ini memberikan transparansi terhadap keputusan model melalui pemeringkatan kepentingan fitur secara global, analisis kontribusi fitur spesifik terhadap jenis kerusakan, serta identifikasi akar penyebab kesalahan klasifikasi (Bengherbia dkk., 2024; Mosca dkk., 2022; Bao dkk., 2025). Aspek kemampuan penjelasan ini krusial untuk meningkatkan kepercayaan dan tingkat adopsi di lingkungan industri manufaktur, mengingat sebagian besar penelitian yang ada menghasilkan model kotak hitam yang sulit dipahami oleh tenaga perawatan (Serradilla dkk., 2022).

Keempat, implementasi langsung pada industri manufaktur bantalan bola riil dengan data waktu nyata dari mesin produksi (OR1 dan OR2). Implementasi dilengkapi dengan validasi lintas mesin, pengujian ketahanan pada berbagai kondisi operasi, serta analisis manfaat-biaya untuk menunjukkan dampak ekonomi konkret (target pengurangan biaya 20-30% dibandingkan perawatan terencana). Penelitian sebelumnya umumnya menggunakan kumpulan data acuan publik (CWRU, IMS, PRONOSTIA) yang tidak mencerminkan kompleksitas lingkungan produksi sebenarnya (Serradilla dkk., 2022; Khorram dkk., 2020; Li dkk., 2025).

Kelima, pengembangan pendekatan hibrid ARIMA-LSTM yang menggabungkan fondasi statistik (ARIMA) untuk pemodelan tren linier dengan kemampuan pembelajaran mendalam (LSTM) untuk pengenalan pola non-linier, sehingga mencapai sinergi antara kemampuan interpretasi dan akurasi tinggi (Hamiane dkk., 2024). Model ini mengatasi keterbatasan metode statistik murni yang tidak dapat menangkap pola degradasi non-linier, sekaligus mengatasi kekurangan pembelajaran mendalam murni yang memerlukan data besar dan kurang dapat diinterpretasi.

I.6.2 Rancangan dan Persiapan Penelitian

Pada tahap ini akan dilakukan perancangan dan persiapan penelitian. Hal pertama yang dilakukan adalah melakukan pengumpulan data-data penelitian. Metode pengumpulan data yang digunakan dalam penelitian ini berasal dari data implementasi teknologi industri 4.0, terutama yang terkait dengan perawatan korektif atau perawatan preventif yang sudah dilakukan. Selain itu dibutuhkan juga data-data dari sistem produksi terkait, data-data dari manajemen kualitas produksi, dan data-data investasi di bidang perawatan. Berdasarkan data-data yang didapatkan, diharapkan penelitian sesuai dengan target yang sudah ditetapkan.

Hal kedua yang dilakukan adalah menyusun kerangka penelitian. Berikut ini merupakan kerangka penelitian yang akan digunakan untuk memprediksi tingkat keausan alat produksi berdasarkan data yang berasal dari sensor (Traini, Guilia, D'Antonio, & Lombardi, 2019).